

Raport: Analiza zbieżności metody gradientu prostego

Grzegorz Topór

1 Opis implementowanego algorytmu

Zaimplementowano algorytm gradientu prostego (ang. *Gradient Descent*). Jest to iteracyjna metoda optymalizacji pierwszego rzędu, służąca do znajdowania lokalnego minimum różniczkowalnej funkcji celu. Reguła aktualizacji parametrów w kroku $t + 1$ zdefiniowana jest wzorem:

$$x_{t+1} = x_t - \alpha \nabla f(x_t)$$

gdzie:

- $x_t \in \mathbb{R}^n$ – wektor parametrów w iteracji t ,
- α – współczynnik uczenia (krok, ang. *learning rate*),
- $\nabla f(x_t)$ – gradient funkcji celu w punkcie x_t .

Algorytm działa iteracyjnie, aż do spełnienia jednego z warunków stopu. Zaimplementowano następujące kryteria zatrzymania:

- osiągnięcie maksymalnej liczby iteracji,
- brak poprawy wartości funkcji celu przez zadaną liczbę kroków,
- wykrycie niestabilności numerycznej (wartości `NaN`, `Inf` lub przekroczenie zakresu zmiennoprzecinkowego).

Algorithm 1 Pseudokod Metody Gradientu Prostego z zabezpieczeniem numerycznym

```
1: function SOLVER( $x_0, \alpha, max\_iter$ )
2:    $x \leftarrow x_0$ 
3:    $best\_val \leftarrow f(x)$ 
4:   for  $t \leftarrow 0$  to  $max\_iter$  do
5:      $g \leftarrow \nabla f(x)$                                  $\triangleright$  Obliczenie gradientu
6:      $x_{new} \leftarrow x - \alpha \cdot g$                    $\triangleright$  Krok aktualizacji
7:      $val \leftarrow f(x_{new})$ 
8:     if  $val$  is NaN or  $val$  is Inf then
9:       Break                                      $\triangleright$  Przerwanie w przypadku eksplozji gradientu
10:      end if
11:      if  $val < best\_val$  then
12:         $best\_val \leftarrow val$ 
13:        Zresetuj licznik patience
14:      end if
15:       $x \leftarrow x_{new}$ 
16:    end for
17:    return Historia wartości funkcji celu
18: end function
```

2 Eksperymenty numeryczne

2.1 Dane i metodyka

Badaniu poddano trzy funkcje testowe optymalizacji w przestrzeni $n = 10$:

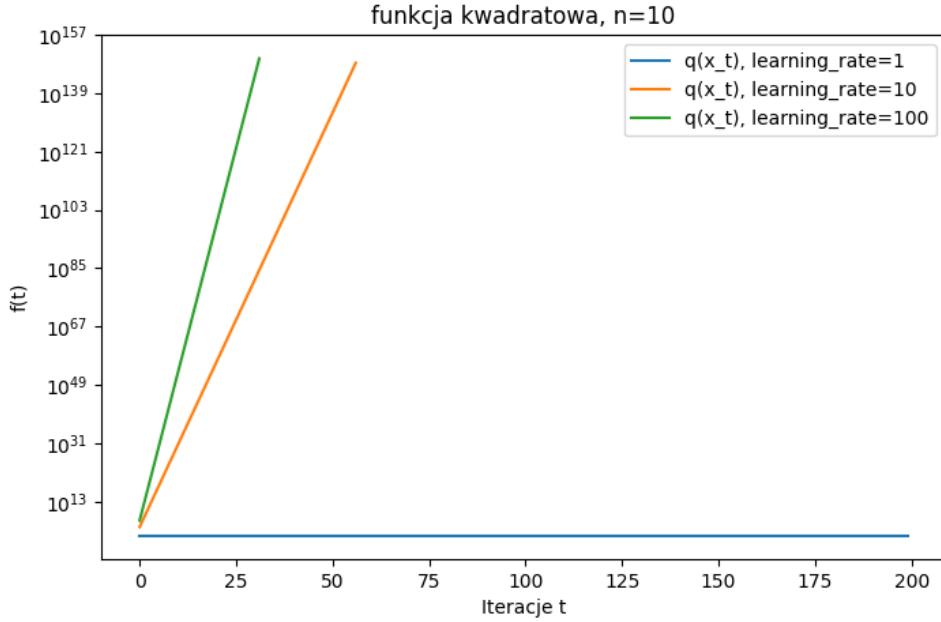
1. **Funkcja kwadratowa**
2. **Funkcja Rosenbrocka**
3. **Funkcja Ackleya**

Jako dziedzinę przyjęto zbiór $[-10, 10]^{10} \subset \mathbb{R}^{10}$. Punkt startowy x_0 został wylosowany z rozkładu jednostajnego wewnątrz dziedziny. Celem eksperymentu było zbadanie wpływu dużych wartości parametru kroku na zbieżność. Przetestowano parametr:

$$\alpha \in \{1, 10, 100\}$$

3 Wyniki

3.1 Funkcja Kwadratowa

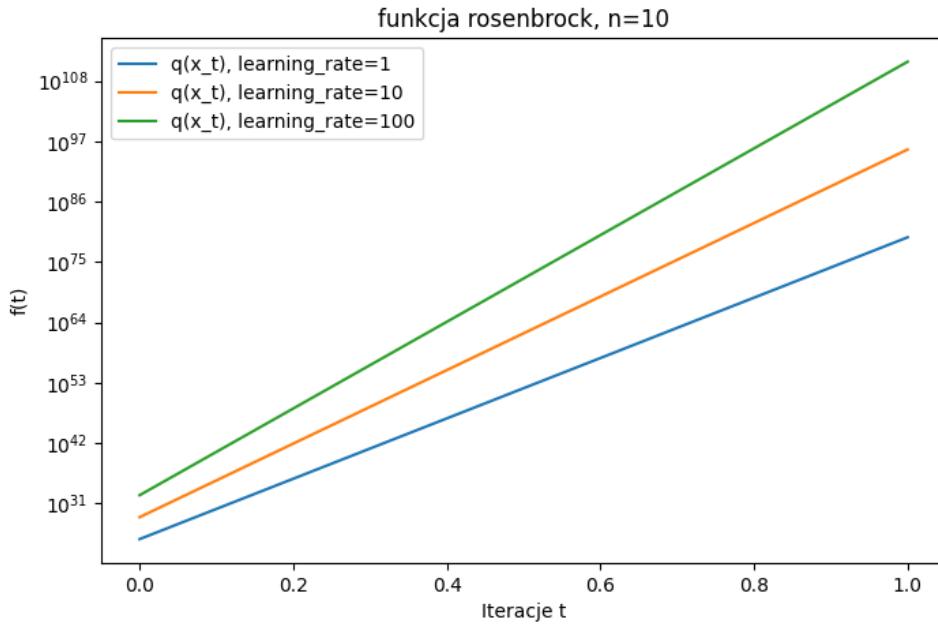


Rysunek 1: Dywergencja funkcji kwadratowej

Dla wartości $\alpha = 10$ i $\alpha = 100$ algorytm uległ dywergencji. Ze względu na brak ograniczeń funkcji kwadratowej, wartości błędu rosną wykładniczo (liniowy wzrost na skali logarytmicznej).

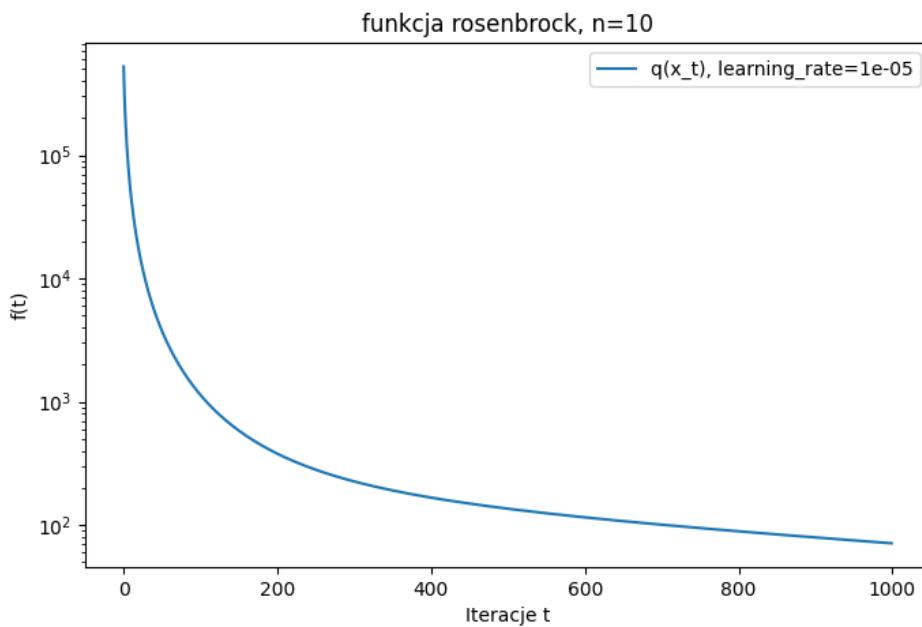
- Dla $\alpha = 100$: Natychmiastowe osiągnięcie progu 10^{150} (ok. 30 iteracji).
- Dla $\alpha = 10$: Prawie natychmiastowe osiągnięcie progu 10^{150} (ok. 50 iteracji).
- Dla $\alpha = 1$: Krok sprawia, że algorytm nie jest zbieżny – oscyluje dookoła jednej wartości.

3.2 Funkcja Rosenbrocka

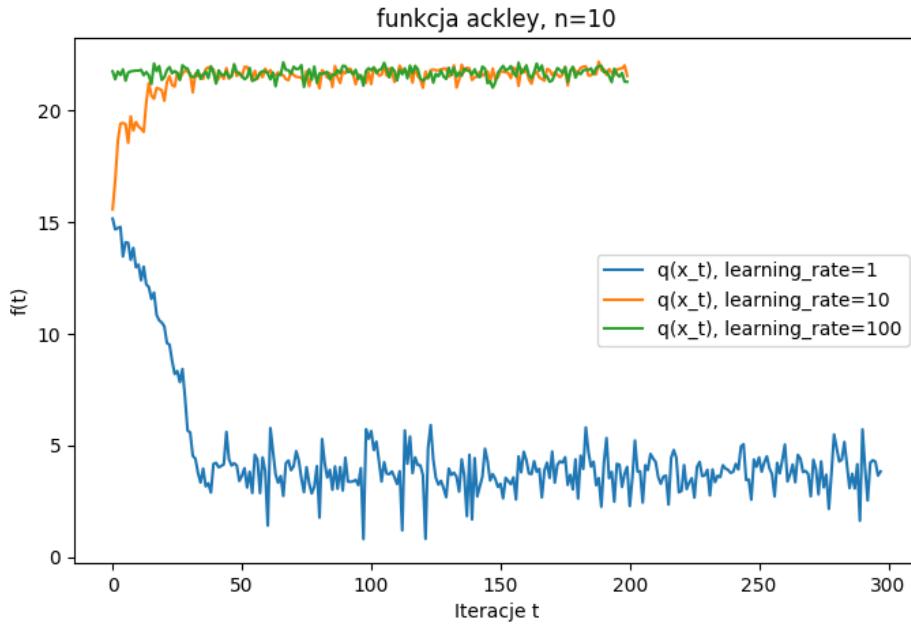


Rysunek 2: Natychmiastowa eksplozja numeryczna dla f. Rosenbrocka.

Funkcja Rosenbrocka w $n = 10$ charakteryzuje się bardzo stromymi zboczami (czwarta potęga zmiennych). Zastosowanie $\alpha \geq 1$ prowadzi do natychmiastowej niestabilności numerycznej. Wykres urywa się po 1. iteracji, ponieważ już w pierwszym kroku wartości funkcji przekraczają zakres precyzji zmiennoprzecinkowej (osiągając rzędy wielkości $10^{30} - 10^{108}$), co wymusiło awaryjne zatrzymanie solvera. Aby przetestować zbieżność algorytmu, α powinna być znacznie mniejsza od 1, np: $\alpha = 0.00001$



3.3 Funkcja Ackleya



Rysunek 3: Stagnacja funkcji Ackleya na plateau.

W przeciwieństwie do funkcji wielomianowych, funkcja Ackleya jest ograniczona (asymptotycznie dąży do stałej wartości przy dużych x).

- Duży krok ($\alpha = 10, 100$) wyrzucił punkt w obszar płaski (plateau), gdzie wartość funkcji wynosi ok. 20-22.
- Algorytm utknął w lokalnym minimum lub na płaskim obszarze z powodu zaniku gradientu ($\nabla f(x) \approx 0$).
- Dla $\alpha = 1$ widoczna jest próba optymalizacji, jednak parametr jest nadal zbyt duży, by osiągnąć zbieżność do minimum globalnego ($f(x) = 0$).

4 Wnioski

1. Badane wartości współczynnika uczenia $\alpha \in \{1, 10, 100\}$ okazały się **zbyt duże** dla problemu optymalizacji w przestrzeni 10-wymiarowej.
2. Metoda gradientu prostego jest wysoce wrażliwa na dobór parametru kroku. Przekroczenie krytycznej wartości prowadzi do niestabilności numerycznej (funkcja Rosenbrocka) lub utknięcia w obszarach zerowego gradientu (funkcja Ackleya).
3. Aby skutecznie zbadać zbieżność, należałoby rozpatrywać parametry α mniejsze od 1.